SPRAWOZDANIE LABORATORYJNE

Zajęcia 2 | Trenowanie i strojenie klasyfikatora obrazów

Przedmiot:	Uczenie głębokie do rozpoznawania obiektów	**Autor:**	Piotr Wójtowicz
Zajęcia nr / temat:	2 - Trenowanie i strojenie klasyfikatora obrazów	**Data:**	25.10.2026

1. Cel ćwiczenia

Na tych zajęciach sprawdziłem, czy da się poprawić model do rozpoznawania ubrań z pierwszego laboratorium. Wytrenowałem kilka wersji modelu i porównałem ich wyniki. Chciałem też zobaczyć, czy model nie dopasowuje się za mocno do danych treningowych.

2. Metoda i implementacja

Pracowałem na zbiorze **FashionMNIST**. Są w nim małe obrazki ubrań o wymiarach 28 × 28 pikseli, podzielone na 10 kategorii. Do trenowania użyłem 50 000 obrazów, a 10 000 zostawiłem do sprawdzania wyników podczas pracy. Na końcu miałem jeszcze osobne 10 000 obrazów testowych.

Mój podstawowy model MLP miał warstwy **784 → 256 → 128 → 10**. Użyłem ReLU, CrossEntropyLoss i optymalizatora Adam. Ustawiłem learning rate 0,001, batch size 128 i **8 epok**. Każdy wariant trenowałem przez tyle samo epok, żeby porównanie było uczciwe.

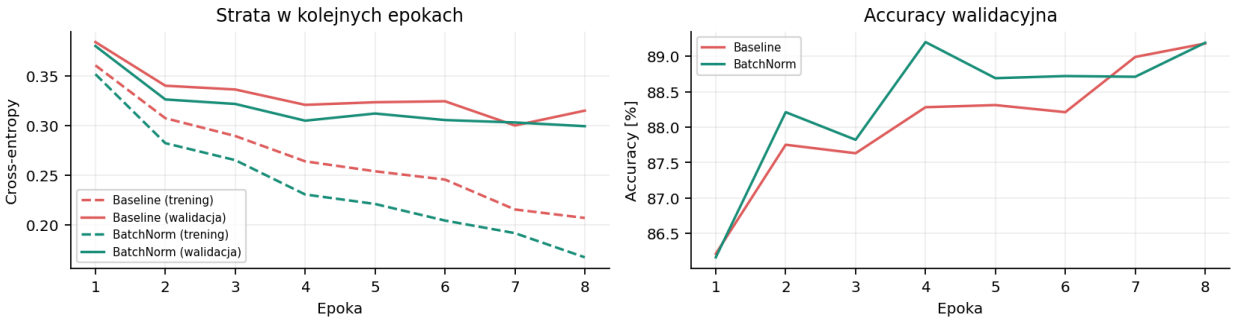
Sprawdziłem cztery zmiany: **dropout 0,2**, **BatchNorm**, **AdamW z weight decay 0,01** i **losowe odbijanie obrazów w poziomie**. Zrobiłem też wersję z połączeniem BatchNorm, dropout i AdamW. Odbijanie obrazów było stosowane tylko podczas treningu.

Cały kod jest w notatniku **Lab2_klasyfikator_FashionMNIST_kod.ipynb**. Model do końcowego testu wybierałem na podstawie wyniku walidacji. Przerwa train-val w tabeli oznacza różnicę między stratą walidacyjną a treningową, liczoną w tych samych warunkach.

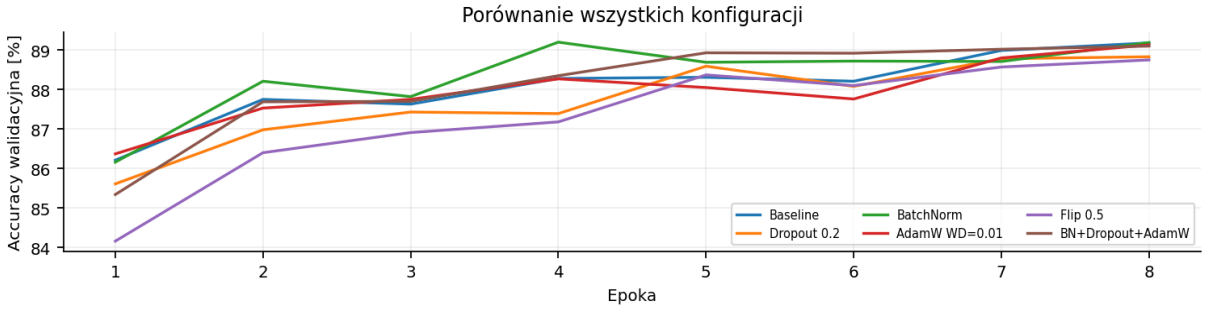
3. Wyniki

Wariant	Najlepsza epoka	Accuracy wal. [%]	Accuracy train [%]	Luka straty val - train
Baseline	8	89.18	92.11	+0.1083
Dropout 0.2	8	88.83	91.16	+0.0690
BatchNorm	4	89.20	91.46	+0.0745
AdamW WD=0.01	8	89.13	92.29	+0.1003
Flip 0.5	8	88.75	90.97	+0.0701
BN+Dropout+AdamW	8	89.10	92.12	+0.0843

Baseline na teście: 88.25% accuracy, przerwa train-test +0.1305.
BatchNorm na teście: 87.89% accuracy, przerwa train-test +0.1048.



Wykres 1. Jak zmieniała się strata i accuracy podczas uczenia baseline oraz BatchNorm.



Wykres 2. Porównanie accuracy wszystkich wersji modelu po każdej epoce.

4. Analiza i interpretacja

Na walidacji najlepiej wyszedł **BatchNorm**, ale był lepszy od baseline tylko o **0.02 punktu procentowego**. To naprawdę mała różnica.

Na końcowym teście ten model był już **gorszy** od baseline o 0.36 p.p. Czyli minimalna przewaga z walidacji nie przełożyła się na lepszy wynik testowy.

Przerwa między stratą treningową a testową **zmniejszyła się** o 0.0257. To sugeruje mniejsze przeuczenie. Jednocześnie widać, że mniejsza przerwa nie musi oznaczać wyższej accuracy.

Na wykresach widać, że strata treningowa ogólnie spadała. Nie zauważyłem dużego przeuczenia w ciągu ośmiu epok.

Ograniczeniem jest to, że każdy wariant uruchomiłem jeden raz. Przy kolejnym uruchomieniu wyniki mogą się trochę różnić. Test sprawdziłem dopiero po wybraniu modelu na walidacji.

5. Wnioski

1. Najlepszy wynik walidacyjny miał BatchNorm, ale na teście lepszy pozostał baseline.

2. Dropout, BatchNorm i inne zmiany mogą ograniczać przeuczenie, ale nie zawsze zwiększają dokładność.

3. W następnym podejściu spróbowałbym dłuższego treningu, kilku powtórzeń albo modelu CNN, który lepiej radzi sobie z obrazami.

Materiały: zadanie, notatnik i wstęp teoretyczny do laboratorium 2.